

實作紀錄: Gemini 多模態 Embedding Pipeline 建置過程

一、任務目標

本次任務的核心目標為強化既有 AI pipeline, 使其具備以下三項能力:

1. 將原有 Text Embedding 模型替換為 Gemini Embedding 模型
 2. 新增多模態 (Multimodal) Embedding 支線
 - 將影片切割為 120 秒片段
 - 直接將影片 (畫面 + 音軌) 輸入模型產生向量
 3. 建立資料入庫流程 (MongoDB)
 - 透過 `mongodb_uploader.py` 將結果寫入資料庫
-

二、初始狀態 (Before)

原始 pipeline 架構如下:

影片

- 抽音 (FFmpeg)
- Whisper STT
- transcript
- normalization
- chunking
- Text Embedding (BAAI/bge-m3)
- JSON 輸出

問題點

- 僅支援文字向量
 - 無法處理:
 - 影片內容語意
 - 視覺資訊
 - 音訊語意 (非文字)
 - 無資料庫整合 (僅檔案輸出)
-

三、需求定義與修正過程(關鍵轉折)

1. 初期誤解(錯誤方向)

一開始將需求理解為：

- 同時保留：
 - 舊 embedding(bge-m3)
 - 新 embedding(Gemini)
- 建立 dual embedding 比較架構

問題

- 與老師需求不符
 - 增加系統複雜度
 - 偏離實務應用方向
-

2. 關鍵修正(需求釐清)

後續明確確認老師需求為：

- 不需要保留舊 embedding
- 不需要做模型比較
- 直接替換 Text Embedding → Gemini
- 新增多模態支線(影片直接 embedding)

此為本次任務最重要的轉折點。

四、最終系統架構(After)

主線(Text Pipeline)

影片

- 抽音
- Whisper STT
- normalization
- chunking
- Gemini Text Embedding
- 輸出 text 向量

支線(Multimodal Pipeline)

影片

- 切割 (120 秒)
 - 多模態模型 (Gemini)
 - 輸出 video embedding 向量
-

資料儲存(MongoDB)

Text Embedding + Video Embedding

- mongodb_uploader.py
 - MongoDB
-

五、實作步驟(Execution Flow)

Step 1: 替換 Text Embedding 模型

原本:

`BAAI/bge-m3`

修改為:

`gemini-embedding-2-preview`

成果

- 成功產生 3072 維向量
 - 已驗證 API 可正常回傳結果
-

Step 2: 建立影片切割機制(Multimodal 前處理)

做法

- 使用 FFmpeg
- 將影片切為:
 - 每段 120 秒
 - 最後一段小於 120 秒

範例輸出

video_001_part_0001.mp4 (0-120s)
video_001_part_0002.mp4 (120-240s)

成果

- 第一部影片成功切為 16 段
 - 每段皆包含完整 metadata (start / end / duration)
-

Step 3: 建立影片多模態 Embedding 支線

流程

影片片段

→ Gemini Embedding 2 (multimodal)
→ 向量輸出

特點

- 不經 Whisper
- 不轉文字
- 直接使用:
 - 畫面
 - 音軌

輸出格式

```
{  
  "clip_id": "...",  
  "video_id": "...",  
  "embedding": [...],  
  "embedding_modality": "video"  
}
```

成果

- 成功產生多模態 video embedding 向量
 - 所有影片片段皆可完成向量化
-

Step 4: 串接 MongoDB

執行方式

```
python mongodb_uploader.py
```

功能

- 將以下資料寫入 MongoDB:
 - text embeddings
 - video embeddings
- 建立可查詢的資料結構

成果

- text 與 video embedding 均成功寫入資料庫
-

六、測試與問題排查

成功部分

- 影片切割成功 (16 clips)
 - pipeline 可完整執行
 - JSON 輸出檔成功建立
 - text embedding 成功
 - video embedding 成功
-

過程中曾遇到的問題

錯誤訊息：

```
403 PERMISSION_DENIED
```

```
Generative Language API has not been used or is disabled
```

原因

- API Key 所屬的 Google 專案尚未啟用 Generative Language API
-

解決方式

- 啟用 Generative Language API
- 等待權限生效
- 重新執行 pipeline

補充觀察

系統曾提示: `Current Gemini client is not using Vertex AI`

表示:

- 多模態影片 embedding 在部分情況可能需透過 Vertex AI
- 但在本次環境設定下, 仍成功完成 embedding

七、目前系統狀態 (Current Status)

項目	狀態
Text Embedding (Gemini)	已完成
影片切割 (120s)	已完成
Multimodal Pipeline	已完成
Video Embedding	已完成
MongoDB 串接	已完成

八、關鍵學習與收穫

Pipeline 設計能力

- 主線與支線拆分設計
- 最小修改原則

多模態 AI 概念

- Text 與 Video embedding 差異

- 同一向量空間的應用價值

工程問題排查

- API 403 與程式錯誤區分
- quota 與權限問題辨識

系統整合能力

- AI 模型 + 資料處理 + 資料庫整合
-

九、總結

本次任務成功完成：

- Text Embedding → Gemini 模型替換
- 建立影片多模態 embedding 支線
- 建立 MongoDB 資料儲存流程
- 成功產出 text 與 video embedding